Language

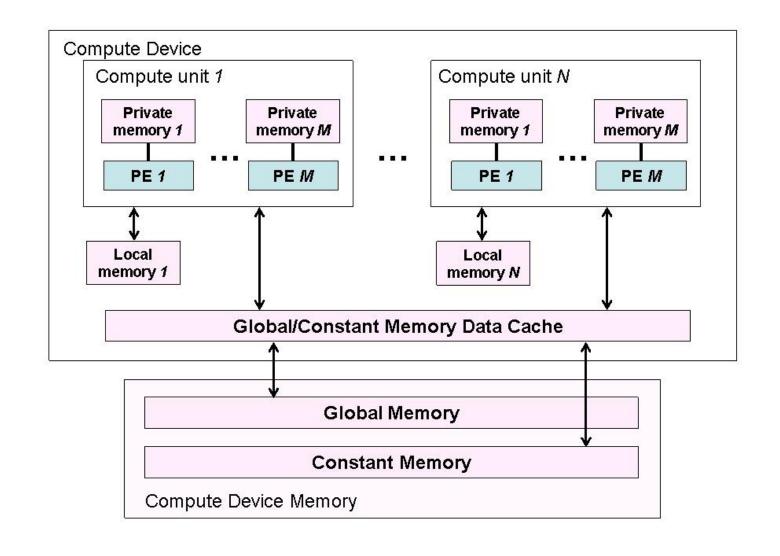
1. OpenCL (OPEN Computing Language)

- 다양한 device, platform을 지원해준다
- CUDA에 비해 코드가 복잡하다

2. CUDA (Compute Unified Device Architecture)

- NVIDIA 제품만 지원한다
- OpenCL에 비해 코드가 간결하다
- 다양한 Library들이 존재한다

OpenCL 구조



OpenCL 동작 과정

| Setup 단계 | |
|------------------------|---|
| Platform 정보 읽기 | AMD OpenCL , Intel OpenCL , NVIDIA OpenCL |
| Device 정보 읽기 | NVIDIA or AMD GPU , FPGA , Intel Xeon |
| Context 생성 | Kernel이 실제로 실행되는 환경을 생성하는 단계 |
| OpenCL program compile | OpenCL application 실행 중에 kernel compile |
| Command queue 생성 | Device 마다 하나 이상의 queue가 필요 |
| Memory object 생성 | Device의 global 혹은 constant memory에 공간 할당 |
| Kernel code 실행 | |
| Data를 GPU memory로 전송 | 입력 값을 전송 |
| Kernel의 argument 설정 | 전송 된 입력 값들 중 kernel argument를 구분해 줌 |
| Kernel 실행 | 동시에 병렬로 실행 |
| Data를 GPU memory에서 전송 | 결과 값을 읽음 |

OpenCL simple code

```
err = clGetPlatformIDs(1, &platform, NULL);
err = clGetDevicelDs(platform, CL_DEVICE_TYPE_GPU, NUM_DEVICES, &device, NULL);
|context = c|CreateContext(NULL, NUM_DEVICES, &device, NULL, NULL, &err);
queue = c|CreateCommandQueue(context, device, 0, &err);
kernel_source = get_source_code("kernel.cl", &kernel_source_size);
program = clCreateProgramWithSource(context, 1, (const char **)&kernel_source, &kernel_source_size, &err);
err = clBuildProgram(program, NUM_DEVICES, &device, "", NULL, NULL);
kernel = clCreateKernel(program, "vec_add", &err);
                                                                __kernel void vec_add(__global int *A, __global int *B, __global int *C)
int A[16384], B[16384], C[16384];
                                                                    int i = get_global_id(0);
for (int idx = 0; idx < 16384; ++idx) {
                                                                    C[i] = A[i] + B[i];
    A[idx] = rand() % 100;
    B[idx] = rand() % 100;
                                                                                      Kernel code in kernel.cl
cl_mem buffer_A, buffer_B, buffer_C;
buffer_A = clCreateBuffer(context, CL_MEM_READ_ONLY, sizeof(int) * 16384, NULL, &err);
buffer_B = clCreateBuffer(context, CL_MEM_READ_ONLY, sizeof(int) * 16384, NULL, &err);
                                                                                                               Setup Phase
|buffer_C = clCreateBuffer(context, CL_MEM_WRITE_ONLY, sizeof(int) * 16384, NULL, &err);
err = clEnqueueWriteBuffer(queue, buffer_A, CL_FALSE, O, sizeof(int) * 16384, A, O, NULL, NULL);
err = clEnqueueWriteBuffer(queue, buffer_B, CL_FALSE, O, sizeof(int) * 16384, B, O, NULL, NULL);
err = clSetKernelArg(kernel, O, CL_MEM_SIZE, &buffer_A);
err = clSetKernelArg(kernel, 1, CL_MEM_SIZE, &buffer_B);
err = clSetKernelArg(kernel, 2, CL_MEM_SIZE, &buffer_C);
size_t global_size = 16384;
size_t local_size = 256;
err = clEnqueueNDRangeKernel(queue, kernel, 1, NULL, &global_size, &local_size, 0, NULL, NULL);
                                                                                                               Running kernel
err = clEnqueueReadBuffer(queue, buffer_C, M2S_TRUE, 0, sizeof(int) * 16384, C, 0, NULL, NULL);
```

문제점

1. 프로그래머가 device의 대부분을 책임진다.

- Device의 global memory를 얼마나 쓸지 할당해야 한다. → clCreateBuffer
- CPU와 GPU간의 Data 전송을 직접 명시해야 한다. → clEnqueueReadBuffer / clEnqueueWriteBuffer
- 만약 어떤 문제로 *data 전송과 kernel 실행 코드가 섞이게* 되면 더욱 복잡한 코드가 된다.

2. 좋은 Performance를 얻기 위해서는 device들의 특성을 알고 있어야한다.

- OpenCL은 다양한 device들을 지원한다. (GPU, FPGA, Xeon, ···)
- Device들은 서로 다른 스펙을 가지고 있다.

```
GTX 1060 1280 cores, global memory 6GB, local memory 1.5 MB
GTX 1080 2560 cores, global memory 8GB, local memory 2 MB
GTX 1080 Ti 3584 cores, global memory 11GB, local memory 2.75 MB
```

. . .

• 같은 코드라도 warp 수, work group 개수 등이 다르다면 같은 device에서도 성능차이가 난다.

M2S

1. 공유 가능한 부분은 공유한다.

• Platform, Context, Program 등의 하나를 공유 할 수 있다면 여러 device들이 공유한다.

2. 공유 할 수 없는 자원들은 struct로 묶는다.

- Device_id, Command_queue 등은 device 마다 고유해야 한다.
- Struct로 묶어 하나로 관리한다.

• Device마다 힌트를 생성한다. ← 핵심 point

M2S

3. 최대한 OpenCL API와 비슷하게 제작한다.

- OpenCL과 비슷한 API로 만들어 하나의 device를 다루고 있다고 생각할 수 있도록 한다.
- OpenCL의 API들과 1:1대응

clGetPlatformIDs : m2sGetPlatformIDs

clGetDevicelDs : m2sGetDevicelDs

clCreateContext : m2sCreateContext

등과 같이 앞부분을 m2s로 바꾼 후, 기능도 OpenCL과 똑같이 만들도록 노력한다.

M2S - Hint 생성

```
cl_uint num_devices;
err = clGetDeviceIDs(platforms[idx], CL_DEVICE_TYPE_ALL, 0, NULL, &num_devices);
devices[idx] = (cl_device_id *)malloc(sizeof(cl_device_id) * num_devices);
err = clGetDeviceIDs(platforms[idx], CL_DEVICE_TYPE_ALL, num_devices, devices[idx], NULL);
for (cl_uint jdx = 0; jdx < num_devices; ++jdx)
{
        err = clGetDeviceInfo(devices[idx][jdx], CL_DEVICE_NAME, 1024, name, NULL);
        err = clGetDeviceInfo(devices[idx][jdx], CL_DEVICE_TYPE, sizeof(cl_device_type), &type, NULL);
        err = clGetDeviceInfo(devices[idx][jdx], CL_DEVICE_VENDOR, 1024, name, NULL);
        err = clGetDeviceInfo(devices[idx][jdx], CL_DEVICE_MAX_COMPUTE_UNITS, sizeof(cl_uint), &cu, NULL);
        err = clGetDeviceInfo(devices[idx][jdx], CL_DEVICE_MAX_WORK_GROUP_SIZE, sizeof(size_t), &wg, NULL);
        err = clGetDeviceInfo(devices[idx][jdx], CL_DEVICE_GLOBAL_MEM_SIZE, sizeof(cl_ulong), &mem, NULL);
        err = clGetDeviceInfo(devices[idx][jdx], CL_DEVICE_LOCAL_MEM_SIZE, sizeof(cl_ulong), &mem, NULL);
        err = clGetDeviceInfo(devices[idx][jdx], CL_DEVICE_MAX_MEM_ALLOC_SIZE, sizeof(cl_ulong), &mem, NULL);
        err = clGetDeviceInfo(de
```

- OpenCL에서는 Device에 대한 정보를 알 수 있도록 API를 제공한다.
- 현재 github에 구현되어 있는 코드는 아직 1/n로 동작하게 되어있다. ← 수정 필요

M2S – data전송 및 kernel 실행

- Device 힌트에 따라서 적절하게 나눈다.
 - 힌트에 따라서 아래와 같이 코드를 반복한다.

```
size_t current_size = 0;
size_t total_size = 0;

for (m2s_uint idx = 1; idx < num; ++idx)
{
    current_size = size + device->device_hint[idx] / 100;

    err = clEnqueueReadBuffer(command_queue.queues[idx], buffer.mems[idx], CL_FALSE, 0, current_size, (void +)((int +)ptr + total_size), 0, NULL, NULL);
    if (err != CL_SUCCESS) {
        printf("EnqueueWriteBuffer Error: cannot write buffer\n");
        return err;
    }

    total_size += current_size;
}
```

M2S – Simple Test (Vector Addition)

현재까지 완성된 M2S로 간단한 vector addition 실험

- 하지만 현재 GPU 부족으로 single-gpu system 상에서 밖에 실험 못 함
- Single-gpu system에서는 data나 task를 나눌 필요가 없기 때문에 잘 동작함
- Microsoft Visual Studio 디버그 콘솔

verification success

D:#workspace#m2s_opencl#Debug#m2s_opencl.exe(12316 프로세스)이(가) 0 코드로 인해 종료되었습니다. 이 창을 닫으려면 아무 키나 누르세요.